

Universidad del Valle de Guatemala
Facultad de Ingeniería
Departamento de Ciencias de la Computación
CC3084 – Data Science
Semestre II – 2026



Laboratorio 1
Series de Tiempo

Análisis del ingreso de viajeros internacionales a Guatemala

Integrantes

Nicolas Concua - 23197

Felipe Aguilar - 23195

Guatemala, 26 de julio de 2026

Resumen del laboratorio

Este informe analiza las series de tiempo del ingreso de viajeros internacionales a Guatemala entre enero de 2009 y junio de 2026 (210 meses consecutivos). El objetivo es caracterizar el comportamiento temporal de la demanda, construir series mensuales por distintas categorías, evaluar su estacionariedad y comparar modelos de pronóstico (ARIMA/SARIMA, Prophet, Holt-Winters, suavizamiento exponencial y seasonal naive). Los datos son de uso exclusivamente académico y no corresponden a cifras oficiales del INGUAT ni del Instituto Guatemalteco de Migración.

Siguiendo la recomendación metodológica del enunciado, la **serie total obligatoria** se define como **Turista + Excursionista**, la única definición consistente en todo el período (la categoría "Viajero" cae artificialmente en 2023 por una reclasificación y "Crucevistas" solo existe hasta 2022). Además de la serie total se seleccionaron **dos categorías de análisis**:

- **Vías de ingreso:** Aérea, Terrestre y Marítima.
- **Países de residencia (Top-3 por acumulado):** El Salvador, Estados Unidos de América y Honduras.

Se obtienen así **siete series mensuales** en total (una obligatoria más seis de las dos categorías). Para la vía Marítima, cuyo detalle Turista+Excursionista se pierde desde 2017, se emplea la serie de **Crucevistas marítimos** disponible de 2009 a 2022; sus comparaciones con las demás vías son indicativas porque no comparten población ni cobertura final.

Nota sobre el Top-3 de países. El ranking literal por acumulado incluía "Guatemala", pero corresponde a residentes guatemaltecos que retornan (no es un mercado de residencia extranjero) y su serie se corta en 2022 por el cambio de granularidad de la variable País desde 2023. Por eso se excluye y se toma el siguiente mercado extranjero con serie completa: Honduras.

1. Análisis exploratorio de datos

El archivo de origen contiene **161,036 filas y 13 columnas** en formato largo: una fila por combinación de mes $\times$ vía $\times$ frontera $\times$ país/agrupación $\times$ tipo de viajero, con la cantidad en la columna Viajero. Combinando Año y Mes se construyó un índice mensual (frecuencia de inicio de mes, MS) que cubre de enero-2009 a junio-2026: **210 meses únicos, sin huecos** en el calendario.

1.1 Calidad de datos: faltantes, duplicados y atípicos

Valores faltantes. No existe ningún valor nulo en las 13 columnas ni en la fecha derivada (0 %).

Duplicados. No hay duplicados exactos ni duplicados de la clave lógica completa (Fecha, Vía, Frontera, País, Tipo de Viajero, Agrupación Residencia). Aparecen unos 20 casos solo si se ignora la columna Agrupación Residencia, pero **no son doble conteo**: corresponden a un país repartido en dos agrupaciones de residencia distintas (por ejemplo, Colombia dividida entre "Colombia" y "Otros Suramérica"). Como la Región dos es idéntica dentro de cada grupo, las agregaciones por fecha, vía, país o región no se ven afectadas.

Valores atípicos. La medida Viajero es fuertemente asimétrica (media 324.7, mediana 7, máximo 92,336) porque son estimaciones de encuesta expandidas, con muchos registros pequeños de mercados menores y pocos registros muy grandes de mercados dominantes. Los "atípicos" del diagrama de caja **no son errores**,

sino la cola natural de la distribución; los decimales son esperados. Hay 54 filas con valor 0 y ninguna negativa. No se requiere imputación ni eliminación para el análisis agregado.




Figura 1. Distribución de la variable *Viajero* (escala logarítmica): confirma la fuerte asimetría de la medida.

En síntesis, el conjunto llega **muy limpio**: sin nulos, sin duplicados reales y sin cantidades negativas.

1.2 Comportamiento temporal del número de viajeros

La serie mensual agregada muestra tres rasgos claros: (1) una **estacionalidad anual** con picos y valles que se repiten cada 12 meses; (2) el **colapso de la pandemia** en marzo de 2020 y un piso profundo en 2020–2021, con recuperación desde 2022; y (3) el **quiebre metodológico de 2023**, tras el cual la categoría "Viajero" se reclasifica. Por eso la serie total se trabaja como Turista + Excursionista, comparable en todo el rango. Debe recordarse que 2026 es un año parcial (solo enero–junio).




Figura 2. Total mensual de viajeros (todos los tipos) 2009–2026, con marcas de la pandemia (2020) y del quiebre metodológico (2023).




Figura 3. Total anual de viajeros; 2026 es un año parcial y no es directamente comparable.

1.3 Composición por tipo de viajero

El acumulado por tipo confirma la decisión metodológica: Turista (37.6 M) y Excursionista (9.1 M) mantienen un patrón estacional continuo, mientras que "Viajero" (4.5 M) se desploma tras 2023 sin ser una caída real de turismo, y Cruceristas (1.1 M) solo existe hasta 2022. Por ello la **serie total se define como Turista + Excursionista**.

Tipo de viajero	Total acumulado
Turista	37,642,728.55
Excursionista	9,069,184.34
Viajero	4,471,622.21
Cruceistas	1,104,402.00




Figura 4. Evolución por tipo de viajero: la curva de "Viajero" cae tras 2023 por reclasificación, no por menor turismo real.

1.4 Países con mayor cantidad de viajeros

Ranking por total acumulado en todo el período (criterio del enunciado). Los mercados grandes (El Salvador, EE. UU., Honduras, México) siguen siendo comparables como serie pese al cambio de granularidad desde 2023.

País / agrupación	Viajeros acumulados
El Salvador	16,213,975.46
Guatemala (retorno nacional)	14,792,331.35
Estados Unidos de América	7,047,842.96
Honduras	2,788,232.82
México	1,808,945.78
Belize	1,328,255.77
Nicaragua	1,164,342.73
Costa Rica	882,179.75
Colombia	561,035.32




Figura 5. Top de países / agrupaciones por viajeros acumulados en todo el periodo.

1.5 Regiones con mayor cantidad de viajeros

Usando la variable Región dos, el mercado está **fuertemente concentrado en América**: América del Centro domina por amplio margen (vecindad terrestre), seguida de América del Norte y Europa.

Región (Región dos)	Viajeros acumulados
América Del Centro	37,406,534.83
América Del Norte	9,383,035.37
Europa	2,222,620.85
América Del Sur y el Caribe	1,447,949.65
Asia	421,702.52
Oceanía	140,047.19
Oriente Medio	135,712.55




Figura 6. Distribución de viajeros por región geográfica (Región dos).

1.6 Vías de ingreso y fronteras más utilizadas

La vía **Terrestre** concentra el 61.2 % de los ingresos (coherente con el peso de Centroamérica), seguida de la **Aérea** (36.5 %) y, muy por detrás, la **Marítima** (2.4 %), que además pierde detalle de registro desde 2017. Las fronteras terrestres con los países vecinos y el aeropuerto La Aurora encabezan el ranking.

Vía de ingreso	Participación (%)
Terrestre	61.2
Aérea	36.5
Marítima	2.4




Figura 7. Participación por vía de ingreso y fronteras más utilizadas.

1.7 Estacionalidad y efecto de la pandemia

Sobre la serie total consistente se aprecia un patrón estacional recurrente y el impacto de 2020: la pandemia provocó una caída abrupta hasta cerca de un cuarto del nivel de 2019, con recuperación progresiva. Este tramo 2020–2021 es un quiebre estructural atípico que condiciona la tendencia y la estacionalidad en el modelado.

Año	Nivel respecto a 2019
2020	25.6 %
2021	26.6 %
2022	78.1 %
2023	70.6 %




Figura 8. Patrón estacional por mes y efecto de la pandemia sobre la serie Total (Turista + Excursionista).

1.8 Resumen del EDA

- **Cobertura:** 210 meses consecutivos sin huecos (ene-2009 a jun-2026); 2026 es parcial.
- **Calidad:** sin nulos, sin duplicados, sin negativos; Viajero es una medida continua asimétrica.
- **Mercados:** fuerte concentración en América (Centro y Norte) y en la vía Terrestre.

- **Quiebres a considerar:** pandemia (2020), quiebre metodológico 2023 (usar Turista + Excursionista), cambio de granularidad de País desde 2023 y pérdida de detalle de la vía Marítima desde 2017.

2. Partición entrenamiento / prueba (70/30)

La partición es **temporal y no se baraja**: el primer 70 % de cada serie se usa para entrenar y el último 30 % para probar. Para las series completas (210 meses) el entrenamiento va de enero-2009 a marzo-2021 (147 meses) y la prueba de abril-2021 a junio-2026 (63 meses). La serie Marítima, más corta (168 meses), entrena hasta septiembre-2018 y prueba de octubre-2018 a diciembre-2022 (51 meses).

Este corte tiene una consecuencia importante y es **un hallazgo, no un defecto**: para las series completas el entrenamiento termina en el piso pandémico y el conjunto de prueba abarca toda la recuperación de ~5 años. Sobre ese horizonte extremo todos los modelos presentan errores altos; por eso más adelante se complementa con una evaluación de horizonte corto (24 meses).

3. Construcción de las series mensuales

Todas las series se construyen a partir del mismo filtro consistente (Turista + Excursionista, salvo la Marítima que usa Cruceristas) y agregación mensual con frecuencia MS. La tabla resume inicio, fin, frecuencia y estadísticos básicos de las **siete series**.

Serie	Inicio	Fin	Frec.	N	Media	Mín.	Máy.
Total	2009-01	2026-06	MS	210	222,437.68	9,779	449,114
Vía Aérea	2009-01	2026-06	MS	210	90,568.66	489	158,463
Vía Terrestre	2009-01	2026-06	MS	210	131,391.68	5,240	291,272
Vía Marítima (Cruceristas)	2009-01	2022-12	MS	168	6,573.82	0	29,506
El Salvador	2009-01	2026-06	MS	210	67,043.50	0	190,579
Estados Unidos de América	2009-01	2026-06	MS	210	33,169.90	0	78,927
Honduras	2009-01	2026-06	MS	210	12,004.64	0	35,253

Tratamiento del cierre pandémico en las series por país. Los únicos meses sin registro son abril–agosto de 2020, cuando las fronteras y el aeropuerto estuvieron cerrados; se rellenan con 0 porque reflejan el cierre real. Estos ceros obligan a usar la transformación $\log_{1p}$ (en lugar de $\log$) al estabilizar la varianza.

4. Análisis de cada serie

Para cada serie se sigue el mismo guion: (a) gráfico e interpretación a primera vista; (b) descomposición y discusión de estacionariedad en media y varianza; (c) decisión de transformación; y (d) estacionariedad en media mediante autocorrelación (ACF/PACF) y las pruebas Dickey-Fuller aumentada (ADF) y KPSS, determinando el número de diferenciaciones d .

4.1 Categoría Vías de ingreso (Total, Aérea, Terrestre, Marítima)

Gráficos e interpretación a primera vista

Serie Total. Tendencia creciente de fondo (2009–2019), estacionalidad anual marcada y colapso abrupto de marzo-2020, seguido de una recuperación que retoma —e incluso supera— niveles previos hacia 2023–2025. La amplitud de las oscilaciones estacionales crece con el nivel (indicio de estacionalidad multiplicativa).

Serie Vía Aérea. Misma estructura (tendencia + estacionalidad + shock de 2020), con menor volatilidad relativa y un piso pandémico aún más profundo (el cierre de aeropuertos golpeó más a la vía aérea que a la terrestre).




Figura 9. Series Total y Vía Aérea (Turista + Excursionista), 2009–jun 2026.

Serie Terrestre. Es la mayor en volumen; tendencia creciente marcada hasta 2019, colapso 2020–2021 y fuerte recuperación desde 2022, con estacionalidad anual visible.

Serie Marítima (Crucelistas). Dominada por una estacionalidad extrema —temporada de cruceros (aprox. oct–abr) frente a meses de verano casi en cero— con interrupción total durante la pandemia. Es una serie intermitente (muchos ceros), lo que la hace especial para el modelado.




Figura 10. Series Vía Terrestre (Turista + Excursionista) y Vía Marítima (Crucevistas).

Descomposición y estacionariedad en varianza

La descomposición aditiva frente a la multiplicativa muestra, en Total, Aérea y Terrestre, un residuo aditivo que se ensancha con el nivel (embudo) mientras que el residuo multiplicativo queda homogéneo alrededor de 1. Esto indica que **la amplitud estacional crece con el nivel** → estacionalidad multiplicativa → series **no estacionarias en varianza**. La media cambia con el tiempo (tendencia + quiebre) → tampoco son estacionarias en media.



Figura 11. Descomposición de la serie Total (tendencia, estacionalidad de período 12 y residuo).




Figura 12. Descomposición de la serie Vía Aérea.



Figura 13. Descomposición de la serie Vía Terrestre.

La media y la desviación estándar móviles (ventana de 12 meses) suben y bajan con el nivel de la serie, confirmando la **no estacionariedad en varianza**. La transformación estándar para estabilizarla es el logaritmo.




Figura 14. Media y desviación estándar móviles (12 meses) de la serie Total: la dispersión sigue al nivel.

Transformación

En el período pre-pandemia (2009–2019, sin quiebre estructural) la correlación nivel–dispersión es alta y positiva (Total +0.85, Aérea +0.87, Terrestre similar) y **desaparece al aplicar log** (cae a valores cercanos a 0 o negativos). Por tanto **sí es necesario transformar**: se usa escala logarítmica (log en las series positivas; log1p en la Marítima, que tiene ceros), invirtiendo con exp/expm1 al evaluar. Dos matices honestos: el log no elimina la tendencia ni la estacionalidad (se aborda con diferenciación), y la pandemia es un quiebre atípico que ninguna transformación simple corrige del todo.



Figura 15. Serie en escala logarítmica: la amplitud de las oscilaciones se vuelve aproximadamente constante.

Estacionariedad en media: ACF/PACF y pruebas ADF/KPSS

En nivel, la ACF conserva picos estacionales y persistencia. Las pruebas formales sobre la muestra completa son ambiguas por el quiebre de 2020: en Total, ADF no rechaza raíz unitaria ($p=0.083$); en Aérea y Terrestre ambas pruebas clasifican el nivel como estacionario, lo que **no** debe leerse como ausencia de tendencia (la descomposición sí muestra tendencia y un cambio de media). Por eso la decisión de d se respalda con una prueba de sensibilidad pre-COVID (2009–2019), donde ADF no rechaza raíz unitaria y KPSS rechaza estacionariedad.




Figura 16. ACF y PACF de la serie Total en nivel (escala log).

Tras **una** diferencia regular ($d = 1$) el diagnóstico se vuelve inequívoco: las series oscilan alrededor de media ~ 0 , ADF rechaza con claridad la raíz unitaria ($p < 0.001$) y KPSS no rechaza estacionariedad. En la

ACF/PACF diferenciada persisten picos en los rezagos estacionales (≈ 12), lo que anticipa una componente estacional (modelos SARIMA).




Figura 17. ACF y PACF de la serie Total tras una diferencia regular ($d = 1$).

Para la **Marítima**, intermitente, no aplica la descomposición multiplicativa (división por cero) y se usa log1p. En nivel no es estacionaria (ADF $p=0.268$, KPSS $p=0.044$) y tras $d = 1$ sí lo es (ADF $p=0.001$). La estacionalidad domina por completo, con picos fuertes en los rezagos 12 y 24: es candidata natural a SARIMA con fuerte componente estacional o a seasonal naive como línea base.

Descomposición aditiva — Marítima (Cruceistas)




Figura 18. Descomposición de la serie Marítima (Cruceistas): la componente estacional domina sobre la tendencia.

Serie	ADF nivel (p)	KPSS nivel (p)	ADF d=1 (p)	KPSS d=1 (p)	d
Total (log)	0.083	0.100	0.0001	0.100	1
Aérea (log)	0.007	0.100	0.0000	0.100	1
Terrestre (log)	0.019	0.100	0.007	0.100	1

Serie	ADF nivel (p)	KPSS nivel (p)	ADF d=1 (p)	KPSS d=1 (p)	d
Marítima (log1p)	0.268	0.044	0.001	0.100	1

Conclusión (Vías). Las cuatro series son no estacionarias en varianza ($\rightarrow$ transformación log/log1p) y requieren $d = 1$ en media, con estacionalidad de período 12 pendiente de modelar con SARIMA.

4.2 Categoría Países de residencia (El Salvador, EE. UU., Honduras)

Gráficos e interpretación a primera vista

El Salvador tiene el mayor volumen y una estacionalidad anual marcada; crece antes de 2020, cae a cero durante el cierre (abr–ago 2020) y se recupera. **Estados Unidos** también crece antes de la pandemia con un patrón estacional más suave y una recuperación sostenida desde 2021. **Honduras** tiene el menor nivel y cambios relativos más bruscos. En las tres, ninguna serie parece tener media constante y la amplitud de sus cambios aumenta con el nivel (varianza no constante).




Figura 19. Series mensuales de El Salvador, Estados Unidos y Honduras (Turista + Excursionista).

Descomposición, transformación y estacionariedad en media

Como existen ceros reales durante el cierre de 2020, no se puede usar descomposición multiplicativa ni el logaritmo usual; se aplica **log1p** y descomposición aditiva. La correlación nivel–dispersión en escala original es alta (El Salvador +0.84, EE. UU. +0.90, Honduras +0.72) y se reduce con log1p, de modo que **sí es necesario transformar** las tres series. El choque pandémico permanece porque es un quiebre real, no un problema de escala.




Figura 20. Descomposición aditiva en escala log1p y relación nivel–dispersión de las tres series de país.

En nivel (muestra completa) las tres series parecen estacionarias según ADF (p entre 0.025 y 0.038) y KPSS ($p > 0.10$), pero esto se debe al efecto combinado de colapso y recuperación. La sensibilidad pre-COVID (2009–2019) muestra que sin la pandemia las series **no** son estacionarias (ADF no rechaza raíz unitaria; KPSS rechaza estacionariedad). Tras una diferencia regular ($d = 1$) las tres quedan claramente estacionarias (ADF $p < 0.001$, KPSS $p > 0.10$).




Figura 21. ACF y PACF de El Salvador en escala log1p (nivel).




Figura 22. ACF y PACF de El Salvador tras una diferencia regular ($d = 1$).

Serie	ADF nivel (p)	KPSS nivel (p)	ADF d=1 (p)	KPSS d=1 (p)	d
El Salvador (log1p)	0.032	0.100	0.0001	0.100	1
Estados Unidos (log1p)	0.038	0.100	0.0000	0.100	1
Honduras (log1p)	0.025	0.100	0.0000	0.100	1

Conclusión (Países). Se adopta $d = 1$ de forma uniforme por la evidencia pre-pandemia y la media creciente; la diferenciación estacional D no se impone, sino que la determina la prueba OCSB dentro de `auto_arima`.

5. Generación de modelos y predicción

Para las siete series se ajustaron modelos **ARIMA/SARIMA** (con órdenes propuestos por `auto_arima` y alternativas manuales) y los algoritmos **Prophet**, **Holt-Winters**, **suavizamiento exponencial simple (SES)** y **seasonal naive**, todos sobre la misma partición 70/30 y la misma escala transformada (invirtiendo al evaluar). La selección de p y q se orienta con ACF/PACF: la PACF sugiere el orden autorregresivo p y la ACF, el orden de medias móviles q ; $d = 1$ se respalda con la sensibilidad pre-COVID, y D lo decide la prueba OCSB.

5.1 Órdenes seleccionados por `auto_arima`

Serie	d	D (OCSB)	Orden auto (p,d,q)	Estacional (P,D,Q,12)
Total	1	0	(2, 1, 2)	(2, 0, 0, 12)
Aérea	1	0	(0, 1, 0)	(1, 0, 1, 12)
Terrestre	1	0	(2, 1, 2)	(2, 0, 0, 12)
Cruceiros marítimos	1	0	(0, 1, 1)	(1, 0, 1, 12)
El Salvador	1	0	(3, 1, 1)	(0, 0, 0, 12)
Estados Unidos de América	1	1	(2, 1, 2)	(0, 1, 0, 12)
Honduras	1	1	(2, 1, 2)	(1, 1, 0, 12)

Interpretación de los parámetros. ARIMA(1,1,1) se mantiene como candidato común porque representa, con mínima complejidad, una dependencia de un mes ($p=1$) y un choque de un mes ($q=1$) tras diferenciar. Las propuestas automáticas se aceptan como candidatos cuando su estructura coincide con las señales anuales de la ACF/PACF, pero se rechazan como modelo final si su RMSE fuera de muestra es peor: en Total, Terrestre y los países los órdenes altos reducen AIC sin mejorar el horizonte largo, señal de sobreajuste al entrenamiento y al quiebre.

5.2 Comparación de modelos ARIMA/SARIMA y algoritmos alternativos

El criterio principal de selección es el **RMSE fuera de muestra**, con MAE como apoyo; AIC/BIC solo comparan dentro de la familia ARIMA. Ljung-Box contrasta ruido blanco ($p > 0.05$ = sin autocorrelación pendiente). Las tablas siguientes muestran los mejores modelos por serie sobre el test 70/30.

Vías de ingreso

Serie / modelo	AIC	BIC	MAE	RMSE	LB p
Total — ARIMA(1,1,1) ✓	92.03	100.98	154,494	169,120	0.08
Total — SARIMA(1,1,1)(0,1,1)12	69.65	81.24	216,558	231,313	1.00
Total — auto SARIMA(2,1,2)(2,0,0)12	63.77	84.65	216,923	234,512	0.70
Aérea — ARIMA(1,1,1) ✓	207.57	216.52	33,226	38,375	0.07
Aérea — auto SARIMA(0,1,0)(1,0,1)12	201.01	209.96	54,283	58,537	0.03
Terrestre — SES ✓	—	—	122,393	134,836	—
Terrestre — ARIMA(1,1,1)	130.74	139.69	123,363	135,843	0.00
Marítima — SES ✓	—	—	5,342	8,082	—
Marítima — ARIMA(1,1,1)	619.14	627.40	5,113	8,425	0.00

El símbolo ✓ marca el mejor modelo por RMSE. En Total y Aérea gana el ARIMA(1,1,1) no estacional; en Terrestre y Marítima gana el suavizamiento exponencial simple (SES).

Países de residencia

Serie / modelo	AIC	BIC	MAE	RMSE	LB p
El Salvador — SES ✓	—	—	81,334	92,860	—
El Salvador — ARIMA(1,1,1)	449.65	458.60	86,534	97,802	0.00
Estados Unidos — ARIMA(1,1,1) ✓	435.86	444.81	22,977	26,796	0.00
Estados Unidos — SES	—	—	24,830	28,635	—
Honduras — ARIMA(1,1,1) ✓	387.60	396.55	14,779	17,194	0.00
Honduras — auto SARIMA(2,1,2)(1,1,0)12	366.61	384.00	16,935	21,006	0.23




Figura 23. Predicción del mejor modelo frente a los datos reales del conjunto de prueba (series de vías).




Figura 24. Predicción del mejor modelo frente a los datos reales del conjunto de prueba (series de país).

5.3 Mejor modelo por serie y calidad predictiva

La siguiente tabla resume el modelo ganador de cada serie con su MAE y RMSE, el RMSE como porcentaje de la media del test y la mejora relativa frente al seasonal naive (una línea base que repite el último año). Una mejora grande indica valor predictivo real sobre esa línea base.

Serie	Modelo	MAE	RMSE	RMSE/media test	Mejora vs naive
Total	ARIMA	154,494	169,120	70.0 %	23.0 %
Aérea	ARIMA	33,226	38,375	40.8 %	51.6 %
Terrestre	SES	122,393	134,836	91.4 %	6.5 %
Crucelistas marítimos	SES	5,342	8,082	160.8 %	31.6 %
El Salvador	SES	81,334	92,860	97.1 %	9.1 %
Estados Unidos de América	ARIMA	22,977	26,796	58.3 %	38.7 %
Honduras	ARIMA	14,779	17,194	85.0 %	17.8 %

Lectura. Aérea (51.6 %) y Estados Unidos (38.7 %) presentan la mejora más clara frente al seasonal naive; su desempeño relativo es favorable pese al quiebre. Marítima (31.6 %) y Total (23.0 %) son moderados. El Salvador (9.1 %) y Terrestre (6.5 %) apenas superan la línea base, con RMSE cercanos a la media del test: su calidad para un horizonte de 63 meses es baja. En Marítima el RMSE supera la media porque el test mezcla meses en cero, período normal y cierre pandémico.

5.4 Diagnóstico de residuos

Los residuos se evalúan en la escala transformada de entrenamiento (media cercana a cero, ACF y Ljung-Box en 12 y 24 meses; $p < 0.05$ indica autocorrelación pendiente).

Serie	Modelo	Media residuo	LB p (12)	LB p (24)
Total	ARIMA	-0.00	0.08	0.01
Aérea	ARIMA	-0.00	0.07	0.49
Terrestre	SES	-0.01	0.00	0.00
Cruceistas marítimos	SES	-0.21	0.00	0.00
El Salvador	SES	-0.00	0.00	0.04
Estados Unidos de América	ARIMA	0.00	0.00	0.08
Honduras	ARIMA	-0.04	0.00	0.20




Figura 25. Diagnóstico de residuos de los siete modelos seleccionados (ACF de residuos).

Lectura. Aérea es el diagnóstico más favorable (Ljung-Box no rechaza en 12 ni 24 meses). Total pasa en el rezago 12 pero falla en 24, conservando memoria de largo plazo. Los modelos SES de Terrestre, Marítima

y El Salvador fallan Ljung-Box: fueron seleccionados por RMSE, no porque expliquen toda la estructura temporal. En consecuencia, los ganadores son útiles como comparación predictiva, pero **no todos producen ruido blanco**; para operación real convendría modelar explícitamente la intervención pandémica y reentrenar con datos recientes.

5.5 Evaluación complementaria: horizonte corto (últimos 24 meses)

El split 70/30 evalúa ~5 años dominados por la recuperación, lo que penaliza a todos los modelos. Como complemento se repite la evaluación reservando solo los últimos 24 meses. En Total, Aérea y Terrestre ese horizonte reciente ya no contiene el salto inicial de pandemia, y los modelos estacionales (**Holt-Winters**, **seasonal naive**) se vuelven competitivos porque el patrón anual vuelve a ser informativo. Por ejemplo, en Total Holt-Winters baja el RMSE a ~20,777 frente a ~49,421 del SARIMA. Marítima es la excepción: sus últimos 24 meses (2021–2022) aún incluyen cierre y recuperación, y allí ARIMA y SES quedan casi empatados. La conclusión es que **el modelo adecuado depende también del horizonte de pronóstico**.

6. Análisis comparativo

Para responder con evidencia estadística se calculan cuatro indicadores de la misma forma para todas las series:

- **Fuerza estacional** de Hyndman: $\max(0, 1 - \text{Var}(\text{residuo}) / \text{Var}(\text{estacional} + \text{residuo}))$, entre 0 y 1, calculada con datos pre-pandemia.
- **Crecimiento anual pre-pandemia**: pendiente de una regresión de $\log_{1p}(\text{serie})$ contra el tiempo (2009–2019), en porcentaje anual.
- **Volatilidad residual**: desviación estándar del residuo de la descomposición $\log_{1p}$ (2009–2019), tras retirar tendencia y estacionalidad.
- **Impacto pandémico**: caída porcentual de abril–diciembre 2020 respecto a los mismos meses de 2019.

Estas definiciones evitan confundir mayor volumen con mayor estacionalidad, crecimiento o volatilidad.

6.1 Indicadores por serie

Serie	Fuerza estacional	Crecim. anual pre-COVID (%)	Volatilidad residual	Caída abr-dic 2020 (%)
Aérea	0.90	5.16	0.04	90.71
Terrestre	0.68	11.16	0.10	95.34
Marítima	0.63	16.66	2.01	100.00
El Salvador	0.57	11.97	0.14	98.70
Estados Unidos	0.94	4.29	0.07	92.61
Honduras	0.54	4.43	0.11	96.97
Total (referencia)	0.79	8.45	0.07	93.67







Figura 26. Comparación de los indicadores (fuerza estacional, crecimiento, volatilidad e impacto pandémico) por serie.

6.2 Respuestas por categoría

Vías de ingreso

- **Mayor estacionalidad: Aérea** (fuerza 0.90), frente a 0.68 de Terrestre y 0.63 de Marítima. Aunque los cruceros tienen una temporada muy clara, sus ceros e intermitencia aumentan el residuo y reducen el indicador.
- **Mayor tendencia de crecimiento: Marítima** (16.66 % anual pre-COVID), seguida de Terrestre (11.16 %) y Aérea (5.16 %). Debe interpretarse con precaución por el bajo volumen e intermitencia de la Marítima.
- **Mayor volatilidad: Marítima** (desviación residual log 2.01), muy por encima de Terrestre (0.10) y Aérea (0.04).
- **Mayor afectación pandémica: Marítima** (caída de 100 %), seguida de Terrestre (95.34 %) y Aérea (90.71 %).

Países de residencia

- **Mayor estacionalidad: Estados Unidos** (fuerza 0.94), muy por encima de El Salvador (0.57) y Honduras (0.54).
- **Mayor tendencia de crecimiento: El Salvador** (11.97 % anual), frente a Honduras (4.43 %) y Estados Unidos (4.29 %).
- **Mayor volatilidad residual: El Salvador** (0.142), seguido de Honduras (0.109) y Estados Unidos (0.065). Al retirar la estacionalidad, Estados Unidos deja de ser el más volátil: gran parte de sus cambios mensuales eran regulares y predecibles.
- **Mayor afectación pandémica: El Salvador** (98.70 %), seguido de Honduras (96.97 %) y Estados Unidos (92.61 %).

6.3 Recuperación durante y después de la pandemia

La caída compara abril–diciembre 2020 con los mismos meses de 2019; la recuperación usa cada año completo como porcentaje de 2019 (=100). No se usa 2026 por ser parcial.

Serie	Caída 2020	2021	2022	2023	2024	2025
Total	93.7	26.6	78.1	70.6	79.2	81.1
Aérea	90.7	47.4	93.7	66.5	77.1	80.2
Terrestre	95.3	14.9	69.4	72.9	80.5	81.7
Cruceros marít.	100.0	3.0	19.9	—	—	—
El Salvador	98.7	18.8	63.5	118.8	134.6	138.0
Estados Unidos	92.6	50.9	97.3	123.4	143.2	146.9
Honduras	97.0	31.0	83.9	175.7	175.6	147.4

Evidencia de recuperación. En 2021 ninguna serie había vuelto al nivel de 2019. Para 2022, Aérea (93.7 %) y Estados Unidos (97.3 %) estaban cerca, mientras Cruceros apenas alcanzaba 19.9 %. Los tres países superaron 2019 en 2023, pero las vías Aérea y Terrestre y el Total todavía estaban alrededor de 80 % en 2025. Esto sugiere un **cambio de composición**: los mercados seleccionados crecieron, pero el agregado consistente no recuperó del todo su nivel previo. La Marítima no tiene datos después de 2022, por lo que

solo se puede afirmar que su recuperación era parcial en ese año (sus valores faltantes posteriores no deben interpretarse como cero).

6.4 Descubrimientos útiles para el INGUAT

- **Planificar por temporada y mercado.** La fuerte estacionalidad de Estados Unidos (0.94) y de la vía Aérea (0.90) permite anticipar meses altos y coordinar campañas, conectividad aérea y capacidad de atención; no conviene repartir el presupuesto de promoción de forma uniforme durante el año.
- **Cuidar el turismo regional terrestre.** El Salvador era el mercado de mayor crecimiento pre-pandemia (11.97 % anual) y la vía Terrestre crecía 11.16 % y concentra la mayoría de viajeros. Facilitar pasos fronterizos y campañas regionales puede tener gran impacto en volumen.
- **Planes de contingencia distintos por vía.** En 2020 la Marítima cayó 100 %, la Terrestre 95.34 % y la Aérea 90.71 %. Una crisis no afecta igual a todos los canales; conviene monitorear y pronosticar cada vía por separado.
- **No usar un solo pronóstico de largo plazo tras un quiebre.** El test 70/30 empieza cerca del piso pandémico y todos los modelos yerran durante la recuperación. Para decisiones operativas conviene reentrenar con frecuencia, usar horizontes cortos e intervalos de incertidumbre, en vez de fijar un plan de cinco años con un modelo entrenado durante la crisis.
- **Mantener consistencia metodológica.** El cambio de clasificación desde 2023 puede confundirse con una caída real; para tableros históricos debe conservarse la definición Turista + Excursionista y señalar que la serie Marítima termina en 2022 bajo la definición de cruceristas.

7. Conclusiones

El conjunto de datos es de alta calidad (210 meses sin huecos, sin nulos ni duplicados reales) y describe una demanda **fuertemente concentrada en América y en la vía Terrestre**, con estacionalidad anual marcada. Las siete series construidas resultan no estacionarias en varianza (se transforman con log o log1p) y no estacionarias en media (requieren una diferencia regular $d = 1$), con una componente estacional de período 12.

En el modelado, la **pandemia de 2020 es el factor determinante de la dificultad de pronóstico**: con la partición 70/30 el entrenamiento termina en el piso pandémico y todos los modelos presentan errores altos sobre los ~5 años de recuperación. En ese horizonte, los modelos parsimoniosos (ARIMA(1,1,1) y suavizamiento exponencial simple) toleran mejor el quiebre y ganan por RMSE; en un horizonte corto y reciente, en cambio, los modelos con estacionalidad recuperan ventaja. La calidad predictiva relativa es claramente favorable en Aérea y Estados Unidos y baja en Terrestre y El Salvador.

Finalmente, el análisis comparativo aporta hallazgos accionables para el INGUAT sobre **cuándo, por dónde y desde qué mercados** llega la demanda, y advierte que un quiebre estructural puede volver poco confiable un modelo histórico si no se reentrena con datos recientes.